



UNIVERSIDADE DO ESTADO DO RIO DE JANEIRO

**Relatório da Investigação de Hiperparâmetros no
Modelo Kohonen aplicado à Base Iris**

Disciplina de Redes Neurais
(IME04-10872)

Aluno Gabriel Maia Pereira da Silva
Matrícula 2024.1.00842.11

Aluno Rafael Manteiga Balbino
Matrícula 2019.2.06491.11

Professora Associada Karla Figueiredo, D.Sc.
Coordenadora do Curso de Ciência da Computação IME/UERJ

Data de Entrega: 11/07/2025
Rio de Janeiro – RJ
2025

1 INTRODUÇÃO.....	1
2 HIPERPARÂMETROS.....	1
2.1 CONFIGURAÇÃO INICIAL.....	2
2.2 CONFIGURAÇÕES SEM HACHURA.....	3
2.2.1 Configuração 1.....	3
2.2.2 Configuração 2.....	4
2.2.3 Configuração 3.....	6
2.2.4 Configuração 4.....	7
2.3 CONFIGURAÇÃO COM HACHURA.....	7
3 CONCLUSÃO.....	9
REFERÊNCIAS.....	10

1 INTRODUÇÃO

Este relatório tem como objetivo expor as investigações acerca do modelo Kohonen, visando encontrar a melhor classificação das amostras, além de analisar o comportamento do mapa auto-organizável em termos de clusterização e visualização de dados.

A base de dados utilizada é a *Íris*. Esta base possui informações sobre plantas do gênero *Íris*, onde podemos encontrar as variáveis, em ordem (FISHER, 1988):

1. comprimento da sépala
2. largura da sépala
3. comprimento da pétala
4. largura da pétala
5. classe

Com a aplicação do modelo Kohonen, espera-se identificar agrupamentos que indiquem a similaridade do grupo de atributos. É importante destacar que, neste caso, a acurácia não deve ser considerada como a principal métrica de avaliação. Embora modelos com alta acurácia (quando comparados posteriormente às classes reais) possam parecer mais precisos, eles podem, na prática, agrupar amostras distintas em poucos clusters, desconsiderando a real diversidade de classes existentes nos dados (GUÉRIN; CHAUVET; SAUBION, 2024).

Assim, modelos que conseguem representar de forma mais fiel à estrutura real dos dados (formando três grupos, como no caso desta base) podem apresentar uma acurácia aparentemente inferior. Como o modelo Kohonen trata-se de um treinamento não supervisionado, os rótulos presentes na base de dados bem como os gráficos rotulados que foram gerados para acompanhar os *SOMs* (Self-organizing Map) serviram somente como um contraste com a realidade, não guiando os princípios de desenvolvimento neste trabalho apresentados.

2 HIPERPARÂMETROS

Os hiperparâmetros correspondem às variáveis que definem a estrutura e o comportamento do processo de treinamento de um modelo (REIS, 2018).


Os hiperparâmetros do modelo apresentado incluem o número de linhas (m) e o número de colunas (n) que definem o tamanho do grid do mapa auto-organizável (*SOM*); a taxa de aprendizado inicial (lr) que controla a velocidade de atualização dos pesos durante o treinamento; o número máximo de iterações ($iters$) que determina quantas vezes o modelo será ajustado; o raio inicial da vizinhança ($radius$) que especifica a área de influência dos neurônios vizinhos no processo de atualização; e a semente aleatória ($rand$) que garante a reprodutibilidade dos resultados.

Para investigação, foram feitas modificações na dimensão do grid, na taxa de aprendizado inicial, no número de iterações e no raio inicial da vizinhança. Não foram realizadas modificações na constante de tempo (τ), vez que esta é calculada automaticamente.

2.1 CONFIGURAÇÃO INICIAL

O código foi executado a partir da configuração inicial para que pudéssemos fazer a análise primária. Segue o resultado:

```
[Randomizer Key: 52]
-----
[SOM - Log de Informações]
Chave Aleatória      : 52
Iterações           : 20000
Topologia            : 10 x 10
Taxa de Aprendizado  : 0.4
Raio Inicial (Sigma) : 5.00
Tau                  : 5112.47
Melhor Acurácia      : 0.833
Sistema Operacional  : Linux #29~24.04.1-Ubuntu SMP PREEMPT_DYNAMIC Thu
Jun 26 14:16:59 UTC 2
Python               : 3.12.3
-----
Plot saved to: .png/som_2025-07-10_22-45-21.png
SOM model saved to: .som/som-model-2025-07-10_22-45-21-0.833.som
```



Foi obtida uma acurácia de 83,3%. Observa-se na imagem que há um agrupamento de 3 regiões de alta ativação de neurônios, mas estes estão espalhados erraticamente, e a baixa acurácia do modelo indica uma problemática de uso real.

A partir disso, foram realizadas diversas mudanças para que fosse possível realizar a melhoria no mapa e no modelo.

2.2 CONFIGURAÇÕES SEM HACHURA

Foi realizada uma gama de testes com diversos ajustes a fim de encontrar a melhor parametrização para o modelo de classificação proposto.

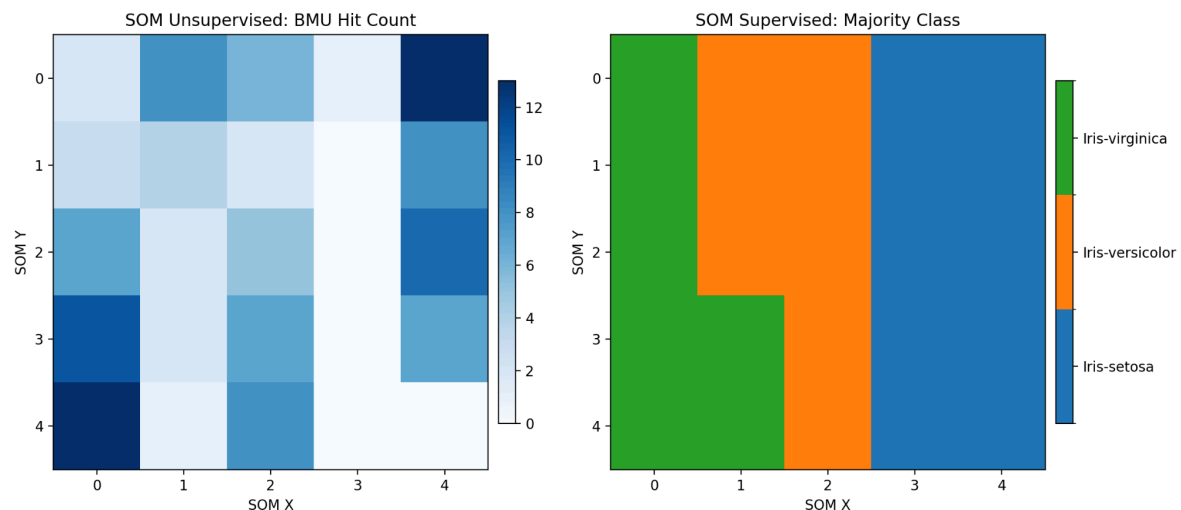
A seguir, serão apresentadas as configurações sem hachura que obtiveram os resultados mais satisfatórios, considerando tanto a acurácia quanto a qualidade do mapa gerado. Dentre essas configurações, uma será selecionada como a mais adequada. Porém o resultado final ideal escolhido foi com hachura, proposto posteriormente. Além disso, será incluído um exemplo de configuração que apresentou desempenho insatisfatório, a fim de possibilitar uma análise crítica e a identificação dos fatores que contribuíram para o resultado inferior.

2.2.1 Configuração 1

[SOM - Log de Informações]

Chave Aleatória : 65
Iterações : 1000
Topologia : 5 x 5
Taxa de Aprendizado : 0.5
Raio Inicial (Sigma) : 3.00
Tau : 910.24
Melhor Acurácia : 0.8333
Sistema Operacional : Windows 10.0.19045
Python : 3.12.9

SOM Visualization
[Randomizer Key: 65]

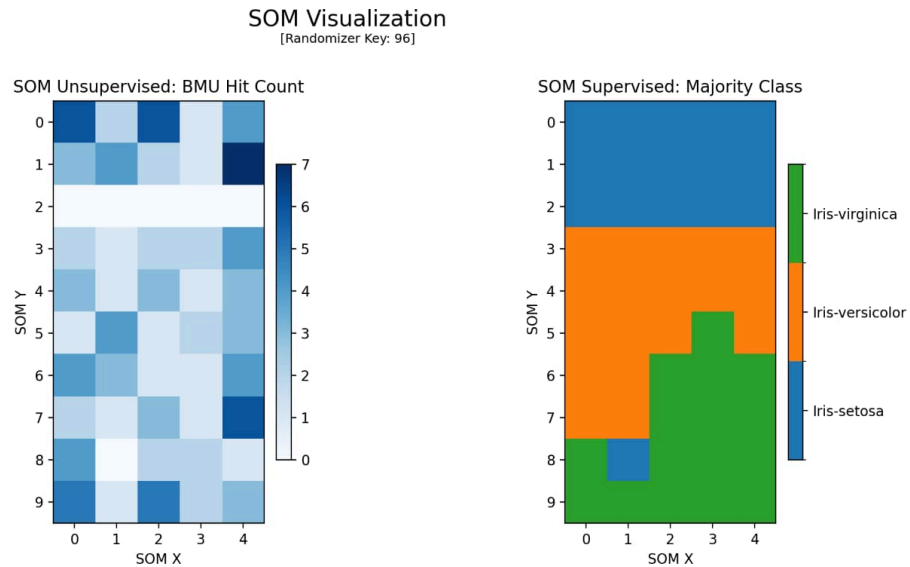


Esta configuração foi melhor do que a original em termos de separação de classes, conforme verificado na imagem. Além disso, apresentou uma acurácia de 83,3%, não apresentando mudança em relação ao inicial.

2.2.2 Configuração 2

[SOM - Log de Informações]

Chave Aleatória : 96
Iterações : 30000
Topologia : 10 x 5
Taxa de Aprendizado : 0.5
Raio Inicial (Sigma) : 2.50
Tau : 32740.70
Melhor Acurácia : 0.967
Sistema Operacional : Linux #1 SMP PREEMPT Tue Jun 3 14:32:57 UTC 2025
Python : 3.12.11



A partir da execução do modelo SOM com uma topologia de 5 x 10, observa-se um claro destacamento de um grupo, evidenciado pela alta frequência de ativação dos neurônios localizados na região superior do mapa, com a presença de um “vale” que demarca a separação entre este grupo e os demais neurônios. Ao comparar o gráfico rotulado (supervisionado, considerando as três classes conhecidas) com o mapa não rotulado (não supervisionado), percebe-se que a distinção entre os atributos associados às classes Iris-versicolor e Iris-setosa não é suficientemente clara.

Esse comportamento indica que, apesar da alta acurácia obtida (96,7% neste caso), o Mapa de Kohonen formado efetivamente realiza a divisão dos dados em apenas dois grupos principais. Tal resultado possivelmente reflete uma menor capacidade explicativa dos atributos presentes na base de dados para separar completamente essas duas classes, que acabam apresentando grande sobreposição nas características analisadas (KLÖSGEN; MAY, 2002).

2.2.3 Configuração 3

[SOM - Log de Informações]

Chave Aleatória : 87

Iterações : 20000

Topologia : 8 x 4

Taxa de Aprendizado : 0.2


Raio Inicial (Sigma) : 1.50

Tau : 49326.07

Melhor Acurácia : 0.867

Sistema Operacional : Linux #1 SMP PREEMPT Tue Jun 3 14:32:57 UTC 2025

Python : 3.12.11



Nesta configuração, com topologia 8×4 e taxa de aprendizado menor (0,2), observou-se uma separação parcial das classes. A acurácia obtida (86,7%) foi inferior às demais, o que pode estar relacionado à combinação de menor raio inicial (1,5) e menor taxa de aprendizado, resultando em um ajuste menos eficaz na atualização dos pesos. O mapa gerado apresentou regiões de transição mais amplas, indicando uma maior dificuldade do modelo em definir fronteiras claras entre as classes Iris-versicolor e Iris-virginica. Ainda assim, a configuração contribuiu para entender o impacto de um raio inicial menor sobre a granularidade do agrupamento.

2.2.4 Configuração 4

[SOM - Log de Informações]

Chave Aleatória : 36

Iterações : 65536

Topologia : 8 x 8

Taxa de Aprendizado : 0.25

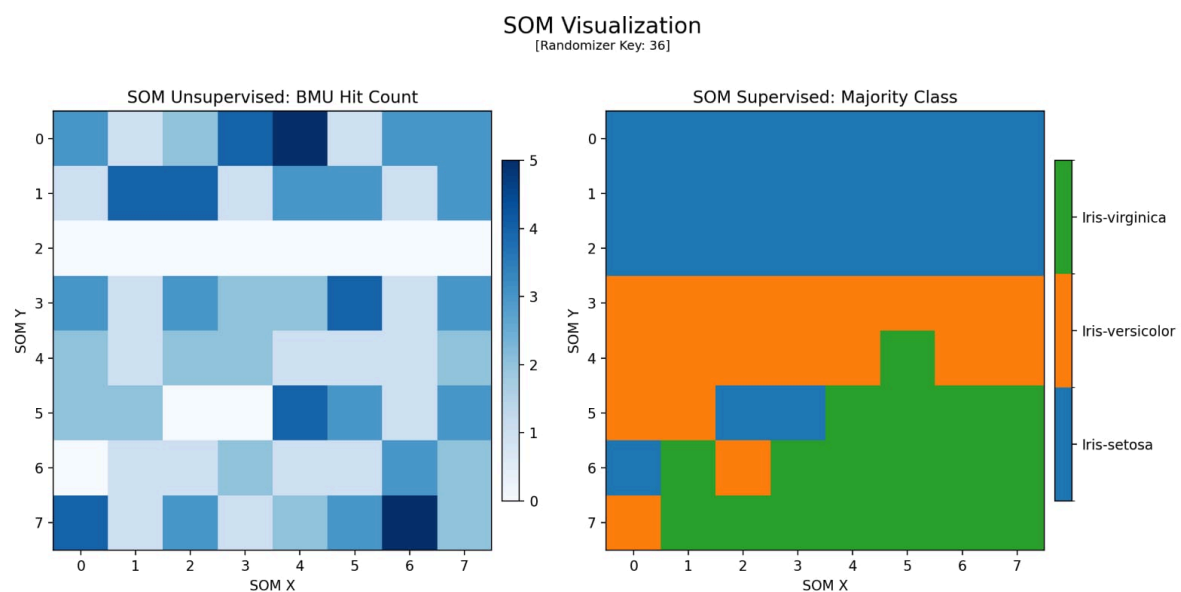
Raio Inicial (Sigma) : 2.00

Tau : 94548.46

Melhor Acurácia : 0.967

Sistema Operacional : Linux #1 SMP PREEMPT Tue Jun 3 14:32:57 UTC 2025

Python : 3.12.11



Nesta configuração, foi utilizada uma topologia 8×8 com maior número de iterações (65536) e uma taxa de aprendizado de 0,25. O mapa resultante apresentou acurácia elevada (96,7%), semelhante à Configuração 2. Entretanto, observou-se uma distribuição mais uniforme dos neurônios ativados, com uma divisão mais clara entre as três espécies. Este resultado evidencia que o aumento das iterações e o uso de um grid maior podem contribuir para uma melhor representação topológica dos dados, reduzindo a sobreposição entre classes.

2.3 CONFIGURAÇÃO COM HACHURA

O uso de hachuras nos gráficos consiste em evitar que as regiões inativas fiquem em branco. Nas configurações anteriores, a topologia apresentada inclui uma grade de neurônios, porém nem todos os neurônios são ativados durante o processamento dos dados. Nos mapas anteriores, as áreas sem ativação apareciam em branco, o que podia gerar confusão, pois as

cores das regiões vizinhas se misturavam visualmente, dificultando a interpretação precisa das zonas de ativação.

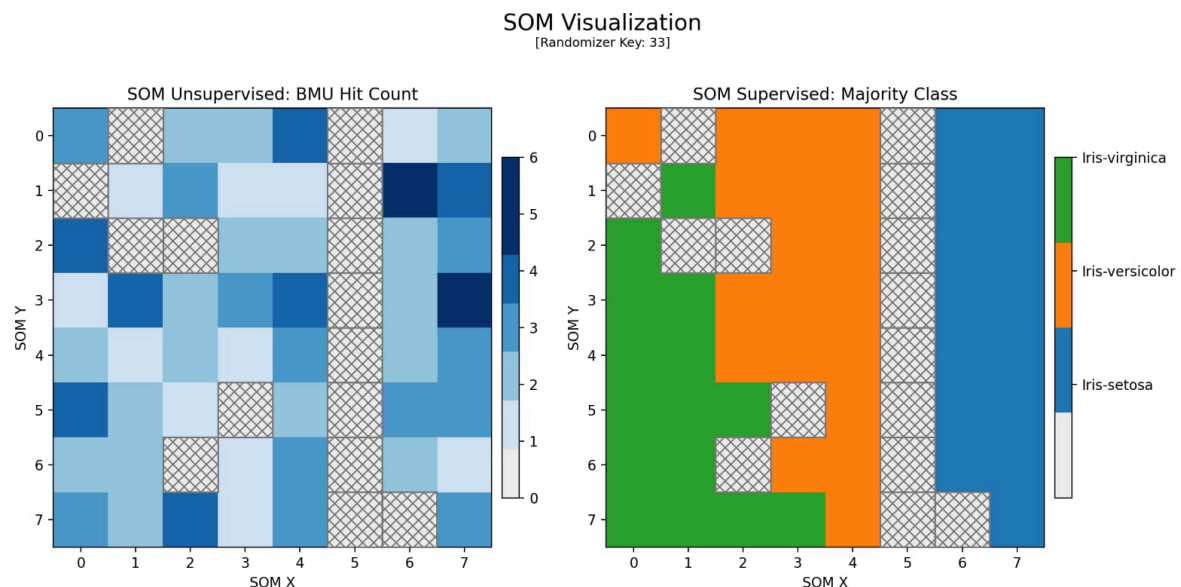
Para solucionar esse problema, foram realizados testes aplicando a técnica de hachura nas regiões não ativadas, tanto em mapas supervisionados quanto não supervisionados. Essa marcação visual nas áreas desativadas permite identificar com maior precisão os “vales” (ou seja, as regiões sem nenhuma ativação) tornando a representação do mapa mais fiel e facilitando a análise (KOHONEN, 2013).

2.3.1 Configuração 5

Arquivo.log:

```
[SOM - Log de Informações]
Chave Aleatória      : 33
Iterações            : 65536
Topologia            : 8 x 8
Taxa de Aprendizado  : 0.25
Raio Inicial (Sigma) : 2.00
Tau                  : 94548.46
Melhor Acurácia      : 0.967
Sistema Operacional  : Linux #1 SMP PREEMPT Tue Jun 3 14:32:57 UTC 2025
Python               : 3.12.11
```

Mapa:



3 CONCLUSÃO

Com base nos experimentos realizados, foi possível observar que os Mapas Auto-Organizáveis (SOM) são capazes de representar a estrutura dos dados de forma visualmente interpretável, permitindo identificar agrupamentos naturais mesmo sem supervisão explícita. As diferentes configurações testadas evidenciaram o impacto direto dos hiperparâmetros na formação dos clusters, demonstrando que uma acurácia elevada nem sempre corresponde a uma segmentação mais fiel das classes reais.

A configuração final escolhida, que incluiu o uso de hachuras para destacar neurônios não ativados, proporcionou uma melhor visualização das regiões de separação entre as espécies, facilitando a análise do comportamento do modelo. Conclui-se, portanto, que além da acurácia, é fundamental considerar a clareza do mapa e a preservação da topologia original dos dados para uma análise exploratória eficaz.

REFERÊNCIAS

FISHER, Ronald. Iris. 1988. Disponível em: <https://archive.ics.uci.edu/dataset/53/iris>. Acesso em: 10 jul. 2025.

GUÉRIN, Axel; CHAUVET, Pierre; SAUBION, Frédéric. A survey on recent advances in self-organizing maps. arXiv preprint, arXiv:2501.08416, 2024. Disponível em: <https://arxiv.org/abs/2501.08416>. Acesso em: 11 jul. 2025.

KLÖSGEN, Willi; MAY, Michael. Spatial subgroup mining integrated in an object-relational spatial database. In: ELOMAA, T.; MANNILA, H.; TOIVONEN, H. (ed.). Principles of data mining and knowledge discovery. Berlin: Springer, 2002. p. 263–275. DOI: https://doi.org/10.1007/3-540-45681-3_23.

KOHONEN, Teuvo. Essentials of the self-organizing map. Neural Networks, v. 37, p. 52-65, 2013.

REIS, Carlos. Otimização de hiperparâmetros em redes neurais profundas. 2018. Disponível em: https://carlos-henreis.github.io/files/Monografia_TFG.pdf. Acesso em: 11 jul. 2025.